Clasificare AMD (Degenerescența Maculară Legată de Vârstă)

Papă Teodora
Universitatea Tehnică „Gheorghe Asachi”, Iași
Facultatea de Automatică și Calculatoare

Facultatea de **AUTOMATICĂ ȘI CALCULATOARE** din Iași

Introducere

Degenerescența Maculară Legată de Vârstă afectează în principal persoanele de peste 50 de ani și provoacă dificultăți de vedere centrală (Fig. 1).

Depistarea timpurie a bolii și identificarea stadiului acesteia ajută la primirea unui tratament adecvat.

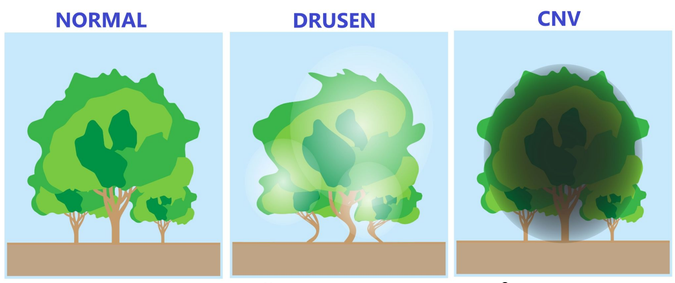


Figura 1. Cum văd persoanele cu AMD[2].

Obiective

Obiectivul proiectului este clasificarea imaginilor OCT 2D ale ochilor (utilizând rețele neuronale convoluționale) în:

- CNV (stadiu avansat, umed, vase de sânge crescute),
- DRUSEN (stadiu incipient, uscat, depozite galbene),
- NORMAL (ochi sănătos).

Set de date

- Conțin imagini OCT 2D:
  -> Kermany OCT 2018[3] (dataset intern de antrenare) -este împărțit în: train, validation și test.
  -> NEH-UT OCT[4] (dataset extern)- este organizat în foldere per pacient și pe ochi (OS, OD).

- Conține imaginile OCT 2D și imaginile segmentate, pe aceeași imagine: -> OIMHS Dataset[5]

Modele utilizate

- Am folosit MobileNetV2 (pre-antrenat pe ImageNet) și am modificat ultimul strat Dense, astfel încât să aibă numărul de ieșiri egal cu numărul de clase.

- Am utilizat ResNet18 (are 18 straturi, pre-antrenat pe ImageNet) pentru cele 3 modele de clasificare a imaginilor segmentate (V1, V2, OIMHS) si cea directă a imaginilor (RN18). Ultimul strat (fc) a fost înlocuit cu unul care are 3 ieșiri (clasele mele).

- Pentru modelul de segmentare utilizat pe setul de date OIMHS am folosit U-Net configurat pe 5 clase (fundal, roșu, verde, albastru, galben) cu structura din figura 3.



Figura 3. Arhitectura pentru segmentarea imaginilor.

Etapele proiectului

S-a aplicat întâi o preprocesare a imaginilor pentru a îmbunătăți claritatea și a accentua detaliile relevante. Evaluarea s-a făcut pe setul de date intern și extern (Fig. 2).

Etapa 1 – clasificarea imaginilor OCT, prin testarea unui model CNN existent (M_Git[1]) și antrenarea a două modele pe setul de antrenare. MNV2 este antrenat cu MobileNetV2 și RN18 cu ResNet18.

Etapa 2 – clasificare cu segmentare, folosind două funcții (V1 și V2) și o metodă automată cu U-Net, antrenată pe setul ce imagini segmentate; măștile generate au fost folosite pentru antrenarea modelelor de clasificare cu ResNet18.

Etapa 3 – interfață interactivă Streamlit pentru rularea rapidă a segmentării și clasificării OCT.

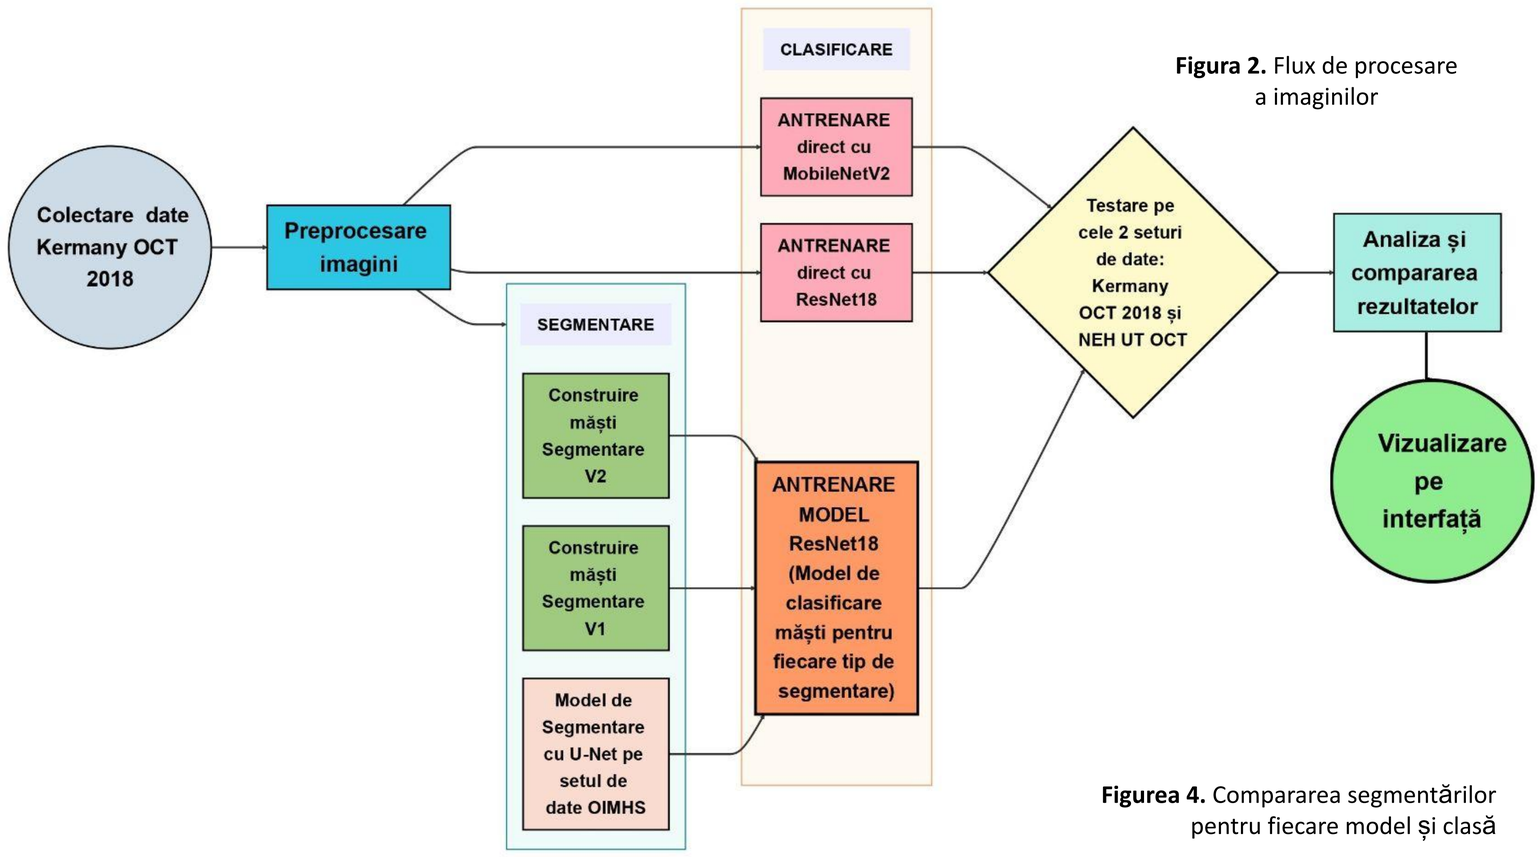
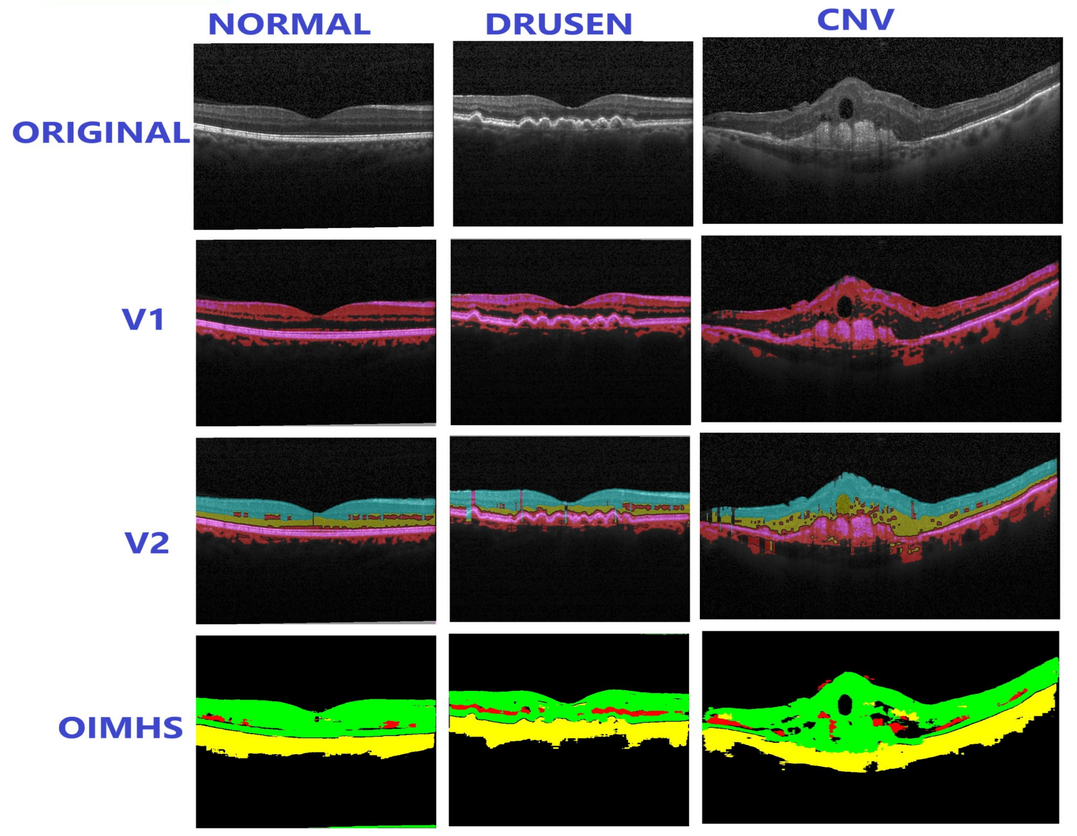


Figura 2. Flux de procesare a imaginilor



Figurea 4. Compararea segmentărilor pentru fiecare model și clasă

Table 1. Rezultate de clasificare pentru cele 2 seturi de date și pentru fiecare model

		Kermany OCT 2018				NEH UT OCT
	Model	Acuratețe	CNV	DRUSEN	NORMAL	Acuratețe
Fără segmentare	M_Git	**~97.66%**	97%	95%	99%	**43%**
	MNV2	**~93.91%**	99%	82%	98%	**58,46%**
	RN18	**~98.76%**	100%	96%	100%	**74,06%**
Cu segmentare	**V1**	**~94.75%**	95%	97%	92%	**66,11%**
	V2	**~92.56%**	97%	90%	90%	**65,97%**
	OIMHS	**~92.84%**	98%	91%	89%	**62,46%**

Rezultate

- Segmentarea nu garantează creșterea performanței.
- Rezultatele pe setul de date extern sunt mai slabe decât cele obținute pe setul de antrenare.

Precision = cât de corecte sunt predicțiile.
Recall = câte exemple adevărate a găsit.
F1-score = scor performanță.

Sursă Date	Clasă	Precision	Recall	F1-score
Intern	CNV	0.96	1.00	0.98
	DRUSEN	1.00	0.96	0.98
	NORMAL	1.00	1.00	1.00
Extern	CNV	0.86	0.89	0.88
	DRUSEN	0.87	0.43	0.58
	NORMAL	0.74	0.85	0.79

Tabel 2. Rezultate pentru modelul RN18 pe setul de date intern și extern

Contact

Papă Teodora
Universitatea Tehnică „Gheorghe Asachi”, Iași
Facultatea de Automatică și Calculatoare
Email: teodora.papa@student.tuiasi.ro
Website: https://ac.tuiasi.ro/

Referințe

[1] ACM Research, Image Classification CNN – OCT model, GitHub, https://github.com/ACM-Research/image-classification-cnn/blob/master/OCT-cnn/python_model/variables/model.h5
[2] Goyal Eye Institute, Age-Related Macular Degeneration (AMD), https://www.goyaleye.com/armd.php
[3] P. T. Mooney, OCT Images (Kermany et al., 2018), Kaggle Dataset, https://www.kaggle.com/datasets/paultimothymooney/kermany2018
[4] O. Orvile, NEH UT OCT Dataset, Kaggle Dataset, https://www.kaggle.com/datasets/orvile/neh-ut-oct-dataset
[5] OIMHS Dataset, Figshare, 2023, https://springernature.figshare.com/articles/dataset/OIMHS_dataset/23508453
[6] B. Fazekas, G. Aresta, SD-RetinaNet: Topologically Constrained Semi-Supervised Retinal Lesion and Layer Segmentation in OCT, arXiv, 2025

© Poster Template by Genigraphics® 1.800.790.4001 www.genigraphics.com